

Aplicación de Autocorrelación Espacial

Estudiante Paul Wenceslao Condori Garcia

Docente Torres Cruz Fred

Curso Estadística Espacial

1. Definición

La **Autocorrelación Espacial** es una medida estadística que cuantifica la similitud de los atributos geográficos o características entre áreas adyacentes. En términos simples, determina si los valores de una variable en una ubicación están relacionados con los valores de esa misma variable (o de otra variable, en el caso bivariado) en las ubicaciones cercanas. Es una técnica utilizada para analizar el agrupamiento espacial (clustering) de valores (similitud o dependencia). Se utiliza típicamente el **Índice de Moran (I)** para cuantificar esta autocorrelación:

- Un valor de I cercano a +1 indica una fuerte autocorrelación positiva, lo que significa que los valores similares se agrupan geográficamente (ejemplo: zonas de Alto-Alto o Bajo-Bajo riesgo o incidencia).
- Un valor de I cercano a -1 indica una autocorrelación negativa, lo que significa que los valores disímiles se agrupan (patrón disperso).
- Un valor de I cercano a 0 indica una distribución espacial aleatoria.

2. Convergencia

La convergencia de los artículos reside en su enfoque metodológico: a pesar de abordar temáticas muy distintas (ecología en China, riesgo costero en Marruecos y salud pública/incidencia de paperas en China), todos emplean técnicas de autocorrelación espacial para:

1. **Cuantificar la Heterogeneidad Espacial:** Demostrar que los fenómenos estudiados (crecimiento de la vegetación, exposición costera o incidencia de enfermedades) no se distribuyen al azar, sino que siguen patrones de agrupamiento geográfico.
2. **Validar la Dependencia Espacial:** Utilizar el Índice de Moran para confirmar que la variación en una ubicación está significativamente influenciada por sus vecinas.
3. **Identificar Puntos Críticos (Hotspots):** Aplicar métodos de autocorrelación local (como LISA) para localizar áreas específicas de alto riesgo (Alto-Alto clustering) o baja incidencia (Bajo-Bajo clustering).

3. Artículos-Aplicación

1. CEcological Indicators:

El estudio sobre las características de la evolución de la vegetación en las Montañas Yinshan, China, utilizó el Análisis de Autocorrelación Espacial Bivariada (Bi-SA) para explorar la correlación entre la vegetación (medida por el índice NDVI) y los factores climáticos.

- **Metodología Específica:** Se empleó el Índice de Moran Bivariado Global
- **Hallazgo Clave:** Se encontró una fuerte correlación espacial positiva entre el NDVI y la precipitación, con un Índice de Moran promedio de 0.88 ($P < 0.01$). Un valor tan cercano a 1 indica que las áreas con alto crecimiento de vegetación tienden a estar cerca de áreas con alta precipitación, lo que implica una distribución geográfica agrupada de esta relación.
- **Conclusión:** La aplicación de la autocorrelación espacial permitió confirmar que la distribución de la vegetación presenta heterogeneidad espacial y que su respuesta a la precipitación está fuertemente correlacionada a nivel espacial.

2. Natural Hazard Research:

El estudio evaluó la exposición costera al aumento del Nivel del Mar (SLR).

- **Metodología Específica:** Se utilizó el Global Moran Index (GMI) para evaluar la autocorrelación espacial de los Índices de Exposición Costera (EI) a lo largo de la costa. Luego, se aplicó el Local Moran Index (LMI/LISA) para evaluar el grado de heterogeneidad espacial entre zonas específicas y sus áreas adyacentes.
- **Hallazgo Clave:** SEI índice de exposición mostró una autocorrelación espacial notable (Índice de Moran de 0.7) en todos los escenarios analizados.
- **Conclusión:** Este alto valor indicó un agrupamiento (clustering) de áreas con exposición similar, lo que significa que el riesgo costero no está distribuido al azar, sino que las zonas con alto riesgo tienden a concentrarse juntas. Esta información es crucial para identificar distritos de alto riesgo para la gestión costera y el desarrollo sostenible.

3. **Frontiers in Public Health:**

El estudio analizó la Heterogeneidad Estratificada Espacial de la incidencia de paperas (mumps) en China y sus factores determinantes.

- **Metodología Específica:** Este artículo se centró principalmente en el análisis de la Heterogeneidad Espacial Estratificada utilizando Geodetector, un método que evalúa el poder explicativo de los factores impulsores sobre la distribución espacial. No obstante, para demostrar la existencia de la heterogeneidad espacial, la literatura en este campo frecuentemente usa o infiere la autocorrelación espacial. El análisis buscó demostrar que la incidencia no era uniforme y estaba agrupada por variables como el clima, la economía y la cobertura de vacunación.
- **Hallazgo Clave:** Se confirmó que la incidencia de paperas presenta una distribución espacial no aleatoria, lo cual es la base para aplicar métodos como Geodetector. Los factores determinantes (como variables demográficas, ambientales y socioeconómicas) influyen de manera diferente en la incidencia según la ubicación geográfica, lo que implica una fuerte dependencia espacial de la enfermedad.
- **Conclusión:** La aplicación de análisis espaciales valida que la incidencia de paperas en China está sujeta a efectos de vecindad y heterogeneidad espacial, y que la correlación entre la enfermedad y sus factores de riesgo varía según la ubicación.

4. **Código en R para la Autocorrelación Espacial**

El método más común para calcular la autocorrelación espacial en R es a través del Índice de Moran utilizando el paquete `spdep`. Este código asume que tiene un archivo geoespacial (como un Shapefile) cargado en un objeto llamado `datos_espaciales` (usando el paquete `sf`) y que la variable de interés se llama `VARIABLE_INTERES`.

```
# 1. Instalar y cargar paquetes necesarios
# install.packages(c("spdep", "sf", "ggplot2"))
library(spdep)
library(sf)
library(ggplot2)

# =====
# PASO 1: Cargar datos (asumimos que ya tienes un objeto sf llamado 'datos_espaciales')
# Ejemplo de carga:
# datos_espaciales <- st_read("ruta/a/tu/shapefile.shp")

# Crear datos de ejemplo si no tienes un shapefile para ejecutar la prueba:
set.seed(42)
coordenadas <- data.frame(
  id = 1:20,
  x = runif(20, 0, 100),
  y = runif(20, 0, 100),
  VARIABLE_INTERES = rnorm(20, mean = 50, sd = 10)
)
datos_espaciales <- st_as_sf(coordenadas, coords = c("x", "y"))
# =====

# PASO 2: Definir la matriz de pesos espaciales (W)
vecinos_k4 <- knearneigh(datos_espaciales, k = 4)
```

```

lista_vecinos <- knn2nb(vecinos_k4)
W <- nb2listw(lista_vecinos, style = "W", zero.policy = TRUE)

# PASO 3: Calcular el Índice de Moran Global
moran_global <- moran.test(datos_espaciales$VARIABLE_INTERES, W, alternative = "two.sided")

# PASO 4: Interpretar el resultado
print("--- Resultado del Moran Global ---")
print(moran_global)

# PASO 5: Calcular el Índice de Moran Local (LISA)
moran_local <- localmoran(datos_espaciales$VARIABLE_INTERES, W)
datos_espaciales$LMI <- moran_local[, 1]
datos_espaciales$p_value <- moran_local[, 5]
datos_espaciales$significante <- datos_espaciales$p_value < 0.05

print("--- Primeras 6 filas del Moran Local (LISA) ---")
print(head(datos_espaciales))

```

5. Conclusiones

La **autocorrelación espacial** demuestra sistemáticamente que los fenómenos geográficos no son aleatorios, sino que presentan una significativa dependencia espacial que resulta en agrupamiento (**clustering**) de valores similares (**hotspots**). Al validar esta dependencia y mapear los puntos críticos (**LISA**), esta técnica proporciona la base para el desarrollo de estrategias de intervención y la formulación de modelos espaciales avanzados y precisos, orientando la toma de decisiones al área geográfica específica que más lo necesita.