

Desarrollo de Código en R para Análisis de Autocorrelación Espacial

Estudiante Paul Wenceslao Condori Garcia
Docente Torres Cruz Fred
Curso Estadística Espacial
Fecha 15 de octubre de 2025

1. Introducción

El presente documento desarrolla una implementación completa en R de cuatro componentes fundamentales del análisis de autocorrelación espacial: (1) Matrices de Pesos Espaciales, (2) Índice I de Moran, (3) Índice C de Geary, y (4) Análisis de Hotspots mediante LISA (Local Indicators of Spatial Association).

La implementación se aplica a datos del departamento de Puno, utilizando 110 distritos como unidades espaciales de análisis.

2. Marco Teórico

2.1. Matrices de Pesos Espaciales

Una matriz de pesos espaciales $\mathbf{W}$ define la estructura de vecindad entre unidades espaciales. Cada elemento w_{ij} cuantifica la relación espacial entre las regiones i y j .

Tipos de matrices implementadas:

- Contigüidad Queen:** $w_{ij} = 1$ si las regiones i y j comparten al menos un vértice o borde
- Contigüidad Rook:** $w_{ij} = 1$ si las regiones i y j comparten un borde común
- K-vecinos más cercanos (KNN):** $w_{ij} = 1$ si j está entre los k vecinos más cercanos de i por distancia euclidiana

Estandarización por filas (estilo W):

$$w_{ij}^* = \frac{w_{ij}}{\sum_{j=1}^n w_{ij}}$$

donde $\sum_{j=1}^n w_{ij}^* = 1$ para cada fila i .

2.2. Índice I de Moran

El Índice I de Moran mide la autocorrelación espacial global, evaluando si valores similares tienden a agruparse espacialmente.

Fórmula:

$$I = \frac{n}{\sum_{i=1}^n \sum_{j=1}^n w_{ij}} \cdot \frac{\sum_{i=1}^n \sum_{j=1}^n w_{ij} (x_i - \bar{x})(x_j - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

donde:

- n = número de unidades espaciales
- x_i = valor de la variable en la región i
- $\bar{x}$ = media de la variable
- w_{ij} = elemento de la matriz de pesos

Interpretación:

- $I > 0$: Autocorrelación positiva (agrupamiento)

- $I \approx 0$: Aleatoriedad espacial
- $I < 0$: Autocorrelación negativa (dispersión)

Valor esperado bajo H_0 (aleatoriedad espacial):

$$E[I] = -\frac{1}{n-1}$$

2.3. Índice C de Geary

El Índice C de Geary es una medida alternativa que enfatiza diferencias entre valores vecinos.

Fórmula:

$$C = \frac{(n-1) \sum_{i=1}^n \sum_{j=1}^n w_{ij} (x_i - x_j)^2}{2 \sum_{i=1}^n \sum_{j=1}^n w_{ij} \sum_{i=1}^n (x_i - \bar{x})^2}$$

Interpretación:

- $C < 1$: Autocorrelación positiva (similitud)
- $C = 1$: Aleatoriedad espacial
- $C > 1$: Autocorrelación negativa (disimilitud)

Relación con Moran: Aproximadamente $C \approx 1 - I$

2.4. Hotspots - Análisis LISA

Los Indicadores Locales de Asociación Espacial (LISA) descomponen la autocorrelación global en contribuciones locales.

Moran Local (I_i):

$$I_i = \frac{(x_i - \bar{x})}{\sigma^2} \sum_{j=1}^n w_{ij} (x_j - \bar{x})$$

donde $\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$

Clasificación de clusters:

- **Alto-Alto (HH):** $x_i > \bar{x}$ y $\sum w_{ij} x_j > \bar{x}$ (Hotspots)
- **Bajo-Bajo (LL):** $x_i < \bar{x}$ y $\sum w_{ij} x_j < \bar{x}$ (Coldspots)
- **Alto-Bajo (HL):** $x_i > \bar{x}$ y $\sum w_{ij} x_j < \bar{x}$ (Outliers)
- **Bajo-Alto (LH):** $x_i < \bar{x}$ y $\sum w_{ij} x_j > \bar{x}$ (Outliers)

3. Implementación en R

3.1. 1. Matrices de Pesos Espaciales

3.1.1. Código

```

1 # Cargar bibliotecas
2 library(sf)
3 library(spdep)
4 library(dplyr)
5
6 # Cargar shapefile y filtrar Puno
7 distritos <- st_read("DISTRITOS.shp")
8 distritos_puno <- distritos %>%
9   filter(substr(UBIGEO, 1, 2) == "21")
10
11 # 1. Matriz de contigüidad Queen
12 vecinos_queen <- poly2nb(distritos_puno, queen = TRUE)
13

```

```
14 # 2. Matriz de contig idad Rook
15 vecinos_rook <- poly2nb(distritos_puno, queen = FALSE)
16
17 # 3. Matriz K-vecinos m s cercanos
18 coords <- st_centroid(st_geometry(distritos_puno))
19 vecinos_knn <- knn2nb(knearneigh(coords, k = 4))
20
21 # Convertir a matriz de pesos (estandarizada por filas)
22 W_queen <- nb2listw(vecinos_queen, style = "W", zero.policy = TRUE)
23 W_knn <- nb2listw(vecinos_knn, style = "W", zero.policy = TRUE)
24
25 # Resumen de vecindarios
26 summary(vecinos_queen)
```

Listing 1: Construcción de matrices de pesos espaciales

3.1.2. Resultados

Característica	Queen	Rook	KNN (k=4)
Número de regiones	110	110	110
Enlaces no-cero	520	520	440
Promedio de vecinos	4.73	4.73	4.00
Regiones sin vecinos	2	2	0
Rango de conectividad	0-10	0-10	4-4
Subgrafos desconectados	3	3	1

Cuadro 1: Características de las matrices de pesos espaciales

Observaciones:

- Las matrices Queen y Rook son idénticas en este caso debido a la naturaleza de los polígonos
- Existen 2 distritos aislados (islas en el Lago Titicaca)
- La matriz KNN garantiza conectividad para todos los distritos
- Se identifican 3 subgrafos desconectados reflejando la geografía compleja de Puno

Vecindarios Queen




Figura 1: Red de vecindarios según criterio Queen. Las líneas rojas conectan distritos vecinos.

3.2. 2. Índice I de Moran

3.2.1. Código

```

1 # Preparar variable de análisis
2 datos_agg <- datos %>%
3   group_by(UBIGEO) %>%
4   summarise(n_registros = n())
5
6 puno_completo <- distritos_puno %>%
7   left_join(datos_agg, by = "UBIGEO") %>%
8   mutate(n_registros = ifelse(is.na(n_registros), 0, n_registros))
9
10 variable <- puno_completo$n_registros
11
12 # Test de Moran
13 moran_test <- moran.test(variable, W_queen, zero.policy = TRUE)
14 print(moran_test)
15
16 # Diagrama de dispersión de Moran
17 moran.plot(variable, W_queen,
18   labels = puno_completo$DISTRITO,
19   xlab = "Variable (estandarizada)",
20   ylab = "Rezago espacial",
21   main = "Diagrama de Dispersión de Moran",
22   zero.policy = TRUE)

```

Listing 2: Cálculo del Índice I de Moran

3.2.2. Resultados

Estadístico	Valor
I de Moran observado	0.2753
$E[I]$ bajo H_0	-0.0093
Varianza	0.003787
Estadístico Z	4.6249
p-valor	1.874×10^{-6}

Cuadro 2: Resultados del test de Moran

Interpretación estadística:

- $I = 0,2753 > E[I] = -0,0093$: Existe autocorrelación espacial positiva
- $Z = 4,6249$: Valor muy significativo (≥ 3)
- $p < 0,001$: Rechazo fuerte de la hipótesis nula de aleatoriedad espacial
- Conclusión: Los valores altos tienden a estar cerca de valores altos, y valores bajos cerca de valores bajos




Figura 2: Diagrama de dispersión de Moran. Los cuadrantes superior-derecho (HH) e inferior-izquierdo (LL) concentran las observaciones, confirmando autocorrelación positiva.

3.3. 3. Índice C de Geary

3.3.1. Código

```
1 # Test de Geary
2 geary_test <- geary.test(variable, W_queen, zero.policy = TRUE)
3 print(geary_test)
4
5 # Interpretación
6 if(geary_test$p.value < 0.05) {
7   if(geary_test$estimate[1] < 1) {
8     cat("Autocorrelación espacial POSITIVA significativa\n")
9   } else {
10    cat("Autocorrelación espacial NEGATIVA significativa\n")
11  }
12 }
```

Listing 3: Cálculo del Índice C de Geary

3.3.2. Resultados

Estadístico	Valor
C de Geary observado	0.7937
$E[C]$ bajo H_0	1.0000
Varianza	0.006745
Estadístico Z	2.5117
p-valor	0.0060

Cuadro 3: Resultados del test de Geary

Interpretación estadística:

- $C = 0,7937 < E[C] = 1,0$: Confirma autocorrelación espacial positiva
- $Z = 2,5117$: Significativo al nivel $\alpha = 0,01$

- $p = 0,006 < 0,01$: Evidencia estadística significativa
- Consistencia: $C \approx 1 - I \rightarrow 0,7937 \approx 1 - 0,2753 = 0,7247$ (relación aproximada)

Comparación Moran vs Geary:

- Ambos detectan autocorrelación espacial positiva significativa
- Moran es más sensible a valores extremos (p-valor menor)
- Geary enfatiza diferencias locales entre vecinos
- Resultados consistentes validan la robustez del análisis

3.4. 4. Análisis de Hotspots (LISA)

3.4.1. Código

```

1 # Calcular Moran Local
2 moran_local <- localmoran(variable, W_queen, zero.policy = TRUE)
3
4 # Agregar resultados al shapefile
5 puno_completo$Ii <- moran_local[, 1]      # Estadístico Ii
6 puno_completo$E_Ii <- moran_local[, 2]    # Valor esperado
7 puno_completo$Var_Ii <- moran_local[, 3]   # Varianza
8 puno_completo$Z_Ii <- moran_local[, 4]    # Z-score
9 puno_completo$p_valor <- moran_local[, 5]  # p-valor
10
11 # Estandarizar variable y calcular rezago espacial
12 puno_completo$variable_std <- scale(variable)
13 puno_completo$lag_std <- lag.listw(W_queen,
14                                   puno_completo$variable_std,
15                                   zero.policy = TRUE)
16
17 # Clasificar tipos de clusters
18 puno_completo <- puno_completo %>%
19   mutate(
20     cluster_type = case_when(
21       p_valor > 0.05 ~ "No significativo",
22       variable_std > 0 & lag_std > 0 ~ "Alto-Alto (HH)",
23       variable_std < 0 & lag_std < 0 ~ "Bajo-Bajo (LL)",
24       variable_std > 0 & lag_std < 0 ~ "Alto-Bajo (HL)",
25       variable_std < 0 & lag_std > 0 ~ "Bajo-Alto (LH)",
26       TRUE ~ "No clasificado"
27     )
28   )
29
30 # Resumen de hotspots
31 table(puno_completo$cluster_type)

```

Listing 4: Cálculo de indicadores LISA y clasificación de hotspots


3.4.2. Resultados

Tipo de Cluster	Frecuencia	Porcentaje
Alto-Alto (HH)	11	10.00 %
Bajo-Alto (LH)	4	3.64 %
No clasificado	2	1.82 %
No significativo	93	84.55 %
Total	110	100.00 %


Cuadro 4: Distribución de tipos de clusters espaciales

Interpretación de clusters:

- **Hotspots (HH):** 11 distritos con alta concentración rodeados de alta concentración
 - Representan el 10 % del territorio
 - Son áreas de interés prioritario
 - Efecto de aglomeración espacial
- **Outliers Bajo-Alto (LH):** 4 distritos con baja concentración rodeados de alta
 - Anomalías espaciales
 - Requieren investigación particular
 - Posibles áreas de transición
- **No significativo:** 84.55 % sin patrón espacial detectado
 - Distribución aleatoria local
 - No contribuyen significativamente a la autocorrelación global




(a) Distribución espacial de la variable



(b) Z-scores del Moran Local

Figura 3: Análisis espacial de la variable de estudio



(a) Significancia estadística ($\alpha = 0,05$)



(b) Clasificación LISA de hotspots

Figura 4: Detección de hotspots y outliers espaciales

3.4.3. Ranking de Distritos Significativos

Cuadro 5: Distritos con autocorrelación local significativa ($p < 0.05$)

Distrito	UBIGEO	N° Reg.	I_i	Z-score	Tipo
PILCUYO	210503	119	-0.274	-5.155***	Bajo-Alto (LH)
CONDURIRI	210505	182	0.768	4.522***	Alto-Alto (HH)
ILAVE	210501	797	7.314	3.521***	Alto-Alto (HH)
TARACO	210607	229	1.325	3.177**	Alto-Alto (HH)
JULI	210401	457	2.896	2.863**	Alto-Alto (HH)
COPANI	211303	230	1.452	2.800**	Alto-Alto (HH)
ACORA	210102	576	3.405	2.558*	Alto-Alto (HH)
SAMAN	210210	338	1.618	2.459*	Alto-Alto (HH)
POMATA	210406	278	1.121	2.370*	Alto-Alto (HH)
PEDRO VILCA	211003	46	-0.570	-2.326*	Bajo-Alto (LH)
APAZA					
HUACULLANI	210403	94	-0.217	-2.268*	Bajo-Alto (LH)
CUTURAPI	211304	2	-1.445	-2.190*	Bajo-Alto (LH)
SAN JUAN DEL ORO	211207	166	0.338	2.190*	Alto-Alto (HH)
CHUPA	210206	193	0.568	2.126*	Alto-Alto (HH)
VILQUE CHICO	210608	243	0.741	2.043*	Alto-Alto (HH)

Nota: * $p < 0.05$, ** $p < 0.01$, *** $p < 0.001$

Hallazgos destacados:

- Hotspot principal - Ilave:**
 - $I_i = 7,314$ (valor más alto)
 - 797 registros (máxima concentración)
 - Núcleo del cluster circunlacustre
- Cluster circunlacustre:** Ilave, Juli, Pomata, Acora forman un hotspot continuo alrededor del Lago Titicaca
- Outlier extremo - Pilcuyo:**
 - $Z = -5,155$ (outlier más significativo)
 - Valor bajo en zona de altos valores
 - Requiere investigación especial
- Cluster secundario:** Conduriri ($I_i = 0,768$, $Z = 4,522$) forma un hotspot significativo en otra región

4. Conclusiones

4.1. Sobre las Matrices de Pesos

- La matriz Queen con 520 enlaces proporciona una representación adecuada de la vecindad espacial en Puno
- La presencia de 3 subgrafos desconectados refleja correctamente la geografía compleja del departamento
- La matriz KNN ofrece una alternativa robusta al garantizar conectividad universal

4.2. Sobre el Índice I de Moran

- $I = 0,2753$ indica autocorrelación espacial positiva moderada-fuerte
- El test es altamente significativo ($p < 0,001$, $Z = 4,625$)
- Se rechaza contundentemente la hipótesis de aleatoriedad espacial
- Existe evidencia clara de agrupamiento espacial en la distribución

4.3. Sobre el Índice C de Geary

- $C = 0,7937 < 1$ confirma autocorrelación positiva
- Resultados consistentes con el Índice de Moran
- El test es significativo ($p = 0,006$, $Z = 2,512$)
- La complementariedad de ambos índices valida la robustez del análisis

4.4. Sobre el Análisis de Hotspots

- Se identificaron 11 hotspots significativos (10 % del territorio)
- El cluster circunlacustre concentra la mayor parte de los hotspots
- Se detectaron 4 outliers espaciales tipo Bajo-Alto que requieren atención especial
- El 84.55 % de los distritos no presenta patrones espaciales locales significativos
- La descomposición local complementa efectivamente el análisis global